

FACULTAD DE INGENIERÍA

CARRERA DE INGENIERÍA DE SISTEMAS COMPUTACIONALES

“DATASALUD EN LA LIBERTAD”

Autores:

Rodríguez Pizán, Mathías Felipe — N00467212

Paredes Pacherre, Carlos Adrián — N00483352

Miranda Amaya, Alina Jaqueline — N00476960

Juárez Garrido, Jhon Alberto — N00475124

Gómez Llerena, Fabrizio Mathías — N00498473

Cruzado Arroyo, Joaquín Mathías — N00467227

Curso:

Base de Datos Avanzada y Big Data

Docente:

Ing. Perez Vigil Jorge Ricardo

Trujillo – Perú

2026-2

Contenido

CONTEXTO PROBLÉMICO	4
Pregunta de Gestión.....	4
Hipótesis.....	5
Delimitación del Proyecto	5
1. Relevamiento, supuestos y articulación.....	6
Descripción del Dominio y Datasets Seleccionados.....	6
Diagnóstico de Calidad de Datos.....	7
Declaración de Supuestos Técnicos y Justificación	7
Articulación curricular y proyección académica	8
2. Automatización (SQL Server)	8
Justificación del diseño elegido.....	8
Objetos Implementados en SQL Server	9
Control Transaccional y Manejo de Excepciones	10
Evidencia de Automatización y Log de Auditoría	11
3. Seguridad y Ley N.° 29733.....	12
Gestión de Roles y Segregación de Privilegios	12
Política de Respaldo y Recuperación (Backup & Restore)	13
Optimización de Rendimiento y Análisis de Plan de Ejecución.....	14
Cumplimiento Normativo e Impacto en los Afectados	15
4. Integración SQL-NoSQL	16
Implementación NoSQL y Operaciones CRUD	16
Análisis Comparativo Técnico (SQL vs NoSQL)	16
5. Data Warehouse y ETL	17
Diseño del Modelo Dimensional	18
Proceso ETL (Extracción, Transformación y Carga)	19
6. Dashboard BI y OLAP.....	19
Fichas Técnicas y Gobernanza de los 3 KPIs Oficiales	20
Demostración de Operaciones OLAP	20
Narrativa con Datos y Respuesta a Preguntas de Negocio	21
7. Análisis Big Data (PySpark)	22
Implementación del Pipeline Distribuido.....	22
Benchmark Comparativo de Tiempos	23
Análisis de Eficiencia y Escalabilidad Computacional.....	24
Reflexión Ética	25
Trazabilidad y Repositorio.....	26

Conclusiones	27
Referencias Bibliográficas	29
Anexos.....	30
Declaración de uso de Inteligencia Artificial	30

CONTEXTO PROBLÉMICO

El Ministerio de Salud del Perú (MINSA) gestiona repositorios de datos abiertos con series históricas que superan los 40 millones de filas, lo que evidencia el volumen crítico de información sanitaria en el país. A pesar de esta vasta disponibilidad de datos, un informe del INEI revela que más del 68% de los establecimientos de salud de primer nivel carecen de mecanismos automatizados para consolidar, validar y auditar sus operaciones. Esta carencia estructural genera inconsistencias severas que afectan directamente la precisión en la toma de decisiones a escala regional y nacional. A esta deficiencia técnica se suma un riesgo legal y normativo: los reportes de la Autoridad Nacional de Protección de Datos (ANPD) del período 2022–2024 exponen brechas sistemáticas en el cumplimiento de la Ley N.º 29733 de Protección de Datos Personales dentro del sector salud. Entre las vulnerabilidades más críticas se destacan la ausencia de logs de auditoría, la falta de segregación de privilegios en los roles de acceso y la existencia de procesos ETL carentes de documentación. Además, la creciente digitalización de los servicios médicos genera volúmenes de datos semiestructurados que desbordan la capacidad de absorción de los sistemas relacionales tradicionales, haciendo urgente la integración de paradigmas NoSQL y herramientas de análisis escalable.

Aterrizando esta problemática al contexto regional, la Dirección Regional de Salud (DIRESA) de La Libertad se enfrenta a una crisis de gestión de datos profunda y silenciosa. La información de atención primaria proveniente de los 312 establecimientos de salud de la región ingresa al sistema plagada de registros duplicados, valores nulos sin control y una absoluta falta de trazabilidad sobre quién modificó un dato o cuándo lo hizo. Esta precariedad técnica paraliza las operaciones analíticas; cuando el director regional requiere cuadros de mando con indicadores vitales —como la carga de morbilidad por grupo etario o los tiempos promedios de atención—, el equipo de gestión de datos confirma la inexistencia de procesos de ingesta automatizados, la ausencia de políticas de respaldo activas y la falta de cualquier modelo analítico operativo.

Frente a este escenario, y aplicando las competencias de la Ingeniería de Sistemas Computacionales, el proyecto aborda el reto de diseñar e implementar desde cero una arquitectura de datos integral que resuelva la crisis de la DIRESA La Libertad considerando solamente procesar dos fuentes masivas de información metaxénica seleccionadas. El desarrollo exige articular tres pilares técnicos de complejidad creciente, anclados siempre en la responsabilidad profesional dictada por el Código de Ética del Colegio de Ingenieros del Perú. Primero, se deberá automatizar la validación e ingesta de los datos crudos del MINSA mediante procedimientos almacenados, triggers y control de excepciones en SQL Server. Segundo, se asegurará la infraestructura tecnológica mediante la implementación estricta de políticas de acceso por roles y mecanismos de auditoría que garanticen el cumplimiento de la Ley N.º 29733. Finalmente, se construirá una solución de inteligencia de negocios basada en un Data Warehouse modelado según la metodología de Ralph Kimball, lo que permitirá transformar millones de registros dispersos en tableros de control fiables que habiliten a la región a tomar decisiones basadas en datos.

Pregunta de Gestión

¿Qué arquitectura automatizada y segura se requiere para consolidar más de un millón de registros históricos de Dengue y Leishmaniasis, garantizando la trazabilidad normativa (Ley N.º 29733) y permitiendo a la DIRESA La Libertad tomar decisiones epidemiológicas basadas en datos a través de un modelo dimensional?

Hipótesis

Si se implementa una arquitectura híbrida de datos que integre el procesamiento transaccional seguro y automatizado (SQL Server) con la flexibilidad documental (mongodb) y el escalamiento distribuido (Apache pyspark), orquestando además un modelo dimensional a través de flujos ETL (SSIS), entonces la DIRESA La Libertad logrará erradicar las inconsistencias de sus registros epidemiológicos históricos, garantizar el blindaje normativo exigido por la Ley N.º 29733 y habilitar una toma de decisiones hospitalarias y operativas basada en tableros de inteligencia de negocios de alta precisión.

Delimitación del Proyecto

Limitación de Datos y Temporalidad: El sistema operará de manera exclusiva con los conjuntos de datos abiertos de "Vigilancia Epidemiológica de Dengue" y "Vigilancia Epidemiológica de Leishmaniasis" descargados del repositorio del MINSA el 15 de septiembre de 2026. No se implementará una conexión API en tiempo real con los servidores del MINSA para actualizaciones continuas; el modelo se basará en un análisis histórico de los cortes de datos disponibles hasta dicha fecha.

Limitación Geográfica: Aunque los datasets originales contienen registros a nivel nacional, los procesos de transformación (ETL), la validación de supuestos geográficos y la visualización final se restringirán únicamente a los registros correspondientes a la jurisdicción de la Dirección Regional de Salud (DIRESA) de La Libertad y sus 312 establecimientos de salud de atención primaria. Las anomalías en regiones ajenas a La Libertad serán descartadas o no tratadas prioritariamente.

Limitación de Implementación en Producción: El proyecto constituye un diseño de ingeniería académico a nivel de prueba de concepto (PoC). No contempla el despliegue del sistema integrado en los servidores de producción físicos o en la nube reales de la DIRESA La Libertad, ni la migración de sus sistemas heredados (legacy) actuales.

1. Relevamiento, supuestos y articulación

Descripción del Dominio y Datasets Seleccionados

El proyecto se centra en la vigilancia epidemiológica de enfermedades metaxénicas bajo la jurisdicción de la DIRESA La Libertad, abarcando 312 establecimientos de atención primaria de salud. Para el diseño analítico, se extrajeron dos conjuntos de datos históricos masivos desde la plataforma nacional de Datos Abiertos del MINSA.

Nombre	Vigilancia Epidemiológica de Leishmaniosis
Fuente	Ministerio de Salud - MINSA
URL	https://www.datosabiertos.gob.pe/dataset/vigilancia-epidemiol%C3%B3gica-de-leishmaniosis
Fecha de Publicación	24/11/2023
Ultima Modificación	02/09/2026
Licencia	Open Data Commons Attribution License
Fecha de Descarga	14/09/2026
Volumen de Registros	156,819

Nombre	Vigilancia Epidemiológica de Dengue
Fuente	Ministerio de Salud - MINSA
URL	https://www.datosabiertos.gob.pe/dataset/vigilancia-epidemiol%C3%B3gica-de-dengue
Fecha de Publicación	22/11/2023
Ultima Modificación	17/12/2025
Licencia	Open Data Commons Attribution License
Fecha de Descarga	14/09/2026
Volumen de Registros	1,029,421

Dimensión de los Datasets		
Campo	Tipo de Dato	Denominación
departamento	Caracter	Región geográfica
provincia	Caracter	Provincia
distrito	Caracter	Lugar probable de infección
localidad	Caracter	Centro poblado o localidad
enfermedad	Caracter	Diagnóstico vigilado
ano (año)	Entero	Año
semana	Entero	Semana de inicio de síntomas
diagnostic	Caracter	CIE 10
diresa	Caracter	Dirección de salud que notifica
ubiego	Caracter	Código de lugar de lugar de infección
loalcod	Entero	Código único RENAES de establecimiento de salud
edad	Caracter	Edad del paciente
tipo_edad	Caracter	Tipo de edad del paciente
sexo	Caracter	Sexo

Diagnóstico de Calidad de Datos

Durante la fase de perfilado de los datos extraídos, se detectaron brechas severas de calidad que justifican la necesidad de un proceso de limpieza transaccional automatizado antes de su ingesta al Data Warehouse.

Problema de calidad	Dataset	Columna afectada	Registros afectados
Valores nulos	V_E_deLeishmaniosis	Localidad, localcod, diresa	53,208
	V_E_deDengue		183,157
Problema de calidad	V_E_deLeishmaniosis	Fila completa afectada	1.119
	V_E_deDengue		152,737
Inconsistencias lógicas	V_E_deLeishmaniosis	edad (> 120)	3
	V_E_deDengue		12

Declaración de Supuestos Técnicos y Justificación

Ante la presencia de datos incompletos y ambiguos, se adoptaron los siguientes supuestos para garantizar la integridad del modelo analítico:

- Tratamiento de Valores Nulos Geográficos e Institucionales.
Dado que existen más de 236,000 registros con valores nulos en columnas críticas (localidad, localcod, diresa), se asume que pertenecen a la jurisdicción general pero carecen de precisión.

Se agrupan bajo un ID comodín ("Ubicación No Especificada" o 'S/C') durante la ingesta automatizada mediante funciones ISNULL(), garantizando que la inserción en la tabla de hechos no falle por violaciones de integridad referencial.

- Eliminación de Duplicados Exactos.

Al detectarse más de 153,000 casos con duplicidad de fila completa, se asume que son fallos de sincronización de los sistemas del MINSA y no episodios clínicos reales.

El código T-SQL exige cláusulas de deduplicación (DISTINCT) para aislar la primera ocurrencia, evitando la inflación de las tasas de morbilidad.

- Control de Inconsistencias Estructurales y Edades Atípicas

Se asume que semanas epidemiológicas fuera del rango (1 a 53) o edades negativas son errores insalvables, mientras que edades irreales (> 120) son errores de digitación rescatables.

Las semanas inválidas se bloquean con ROLLBACK mediante un trigger para proteger la base de datos. Las edades > 120 se transforman al valor numérico centinela 999 y la función escalar normativa las categoriza como etapa de vida "DESCONOCIDO", salvando el caso epidemiológico sin distorsionar la demografía.

Articulación curricular y proyección académica

El diseño arquitectónico de este proyecto integrador no opera de forma aislada, sino que actúa como un eje transversal que consolida competencias previas y cimienta infraestructuras técnicas para retos académicos superiores.

Saberes Previos Retomados y Escalados desde Base de Datos - Ciclo 3. Los fundamentos relacionales adquiridos previamente fueron retomados y escalados hacia una arquitectura de alta disponibilidad y tolerancia a fallos:

- **Transaccionalidad (ACID) a Control Granular:** Se evolucionó del uso básico de COMMIT/ROLLBACK hacia el diseño de transacciones anidadas y manejo estructurado de excepciones (BEGIN TRY / CATCH). La implementación de SAVEPOINT demuestra un dominio avanzado, permitiendo aislar y revertir operaciones médicas corruptas (ej. edades negativas) sin sacrificar la conexión ni el lote masivo completo.
- **DML Tradicional a DML Defensivo:** Se superó la inserción directa de datos para implementar un esquema de "Defensa en Profundidad". Se utilizaron procedimientos almacenados y triggers (trg_Integridad_Semana, trg_Auditoria_Insert) como escudos nativos a nivel del motor relacional, bloqueando alteraciones indebidas.
- **Seguridad Básica a RBAC Normativo:** La creación de usuarios se elevó a un modelo de Control de Acceso Basado en Roles (RBAC). Se aplicaron sentencias de restricción absoluta (DENY) para mapear técnicamente los requisitos legales de la Ley N.º 29733 (Principio de Seguridad) y la ISO 27001.

Preparación y Competencias para Cursos Posteriores. Este proyecto entrega un ecosistema de datos validado y estructurado, desarrollando competencias directas para las siguientes disciplinas:

- **Inteligencia de Negocios (BI):** Provee la competencia técnica de transicionar de un modelo fuertemente normalizado (3NF) hacia un modelo desnormalizado para analítica (Esquema Estrella de Ralph Kimball). El equipo ahora domina la orquestación de flujos ETL (SSIS) y la creación de un modelo semántico preparado para filtros cruzados masivos.
- **Ingeniería de Software:** Desarrolla la capacidad de pensar en arquitecturas desacopladas. Al utilizar bases de datos con auditoría autónoma, la futura capa de aplicación (Backend) se libera de la carga de registrar logs de seguridad, delegando esa responsabilidad al motor de base de datos.
- **Ciencia de Datos / Big Data:** Al integrar MongoDB (Persistencia Políglota) y purgar más de un millón de registros de la DIRESA (eliminando nulos, duplicados y valores atípicos), se entrega un Dataset de alta pureza. Esta es la competencia de "Preparación de Datos" fundamental antes de someter la información a entrenamientos de Machine Learning o procesamiento distribuido en clústeres con PySpark.

2. Automatización (SQL Server)

Justificación del diseño elegido

Para la consolidación y limpieza del millón de registros epidemiológicos, se evaluó extraer los datos crudos hacia un script externo mediante Python y Pandas en la capa de aplicación, frente a

la alternativa de depurarlos nativamente dentro del motor de base de datos con un Enfoque In-Database mediante T-SQL.

Criterio	SQL Server	Python + Pandas
Validación	Alta	Alta
Carga masiva	Alta	Media/Alta
Auditoría	Alta	Media

Luego de evaluar cada opción se optó definitivamente por el Enfoque In-Database, logrando resolver todas las inconsistencias estructurales directamente con T-SQL, basando la decisión en cuatro criterios técnicos específicos. Primero, la implementación de una vista de abstracción (vw_stg_vigilancia_minsa) durante el BULK INSERT garantiza una ingesta masiva veloz desde los archivos CSV, evadiendo colisiones de mapeo con la columna autoincremental de la tabla de destino. Segundo, la lógica de negocio normativa del MINSA se ha modularizado utilizando una función escalar (fn_ClasificarCursoVida), lo que permite clasificar dinámicamente las etapas de vida del paciente desde la base de datos y evitar redundancias de cálculo en la futura capa de Inteligencia de Negocios.

Tercero, la gestión transaccional supera el estándar básico al integrar bloques TRY/CATCH con puntos de guardado (SAVE TRANSACTION); esto asegura que, ante un lote de datos anómalos, el motor deshaga exclusivamente la operación fallida sin anular el progreso de las inserciones previas ni bloquear la conexión. Finalmente, se diseñó una arquitectura de 'Defensa en Profundidad' para la integridad de los datos: mientras que los procedimientos almacenados filtran los registros de forma preventiva como primera línea de defensa, los triggers de integridad (ej. trg_Integridad_Semana) actúan como un blindaje inquebrantable a nivel del motor, rechazando cualquier intento de manipulación manual directa y registrando la infracción. Esta doble barrera garantiza de forma infalible el cumplimiento de la Ley N.º 29733."

Objetos Implementados en SQL Server

Se desarrolló una arquitectura basada en cinco objetos fundamentales para garantizar la automatización

- **Procedimiento Almacenado de Ingesta Masiva (sp_IngestarDesdeStaging):**
Automatiza la limpieza y traslado de lotes masivos desde la tabla de staging (stg_vigilancia_minsa) hacia la tabla transaccional definitiva. Ejecuta transformaciones en vuelo (eliminación de comillas, manejo de valores vacíos con ISNULL) y aplica la regla de negocio crítica que convierte edades irreales (> 120) en el valor centinela 999. Todo el bloque está protegido por SAVE TRANSACTION PuntoStaging, lo que permite revertir fallos masivos y registrar automáticamente el éxito (INGESTA_STAGING) o el fallo (ERROR_INGESTA) en la tabla de auditoría sin romper la conexión.
- **Procedimiento Almacenado de Inserción Individual (sp_ValidarYRegistrarCaso):**
Gestiona el ingreso unitario de nuevos reportes médicos. Antes de interactuar con la tabla principal, ejecuta validaciones lógicas preventivas lanzando excepciones personalizadas (THROW) si la semana no está entre 1 y 53, o si la edad es negativa. Utiliza SAVE

TRANSACTION PuntoValidacion para deshacer la operación en caso de error, registrando el suceso detallado en la auditoría (INSERT_INDIVIDUAL o RECHAZO_SP).

- **Trigger DML de Integridad (trg_Integridad_Semana):** Actúa como segunda línea de defensa inquebrantable a nivel del motor. No solo vigila las inserciones (AFTER INSERT), sino que también se dispara tras cualquier intento de modificación manual (AFTER UPDATE). Si detecta que una transacción intenta vulnerar las reglas de negocio (semanas o edades inválidas), ejecuta inmediatamente un ROLLBACK TRANSACTION, bloquea la alteración de la tabla y deja documentada la infracción (RECHAZO_INTEGRIDAD) en el log, evitando la corrupción a largo plazo.
- **Trigger DML de Auditoría (trg_Auditoria_Insert):** Es el pilar del cumplimiento normativo (Ley N.º 29733 de Protección de Datos Personales). Tras cada inserción exitosa en la tabla de notificaciones, este disparador captura de forma invisible, autónoma e inmutable el usuario del sistema responsable de la acción (SYSTEM_USER), la marca de tiempo exacta (GETDATE()) y la cantidad de filas afectadas, centralizando la trazabilidad en la tabla Log_Auditoria.
- **Función Escalar Normativa (fn_ClasificarCursoVida):** Abstrae y centraliza la lógica de categorización demográfica del MINSA. Evalúa dinámicamente si la edad ingresada está en meses ('M') o días ('D') para catalogar al paciente directamente como 'NIÑO'. Además, gestiona los valores nulos o el valor centinela 999 asignándoles la etiqueta 'DESCONOCIDO', garantizando que los datos anómalos no corrompan los cálculos estadísticos en la fase de Inteligencia de Negocios.

Control Transaccional y Manejo de Excepciones

La robustez de los procedimientos almacenados desarrollados se sostiene en un manejo avanzado de excepciones mediante los siguientes bloques:

```
BEGIN TRY
```

```
...
```

```
END TRY
```

```
BEGIN CATCH
```

```
...
```

```
END CATCH.
```

Dentro del procedimiento sp_ValidarYRegistrarCaso, se implementó la sentencia SAVE TRANSACTION PuntoValidacion, garantizando que, si se detecta un valor atípico insalvable (forzando una excepción con THROW), el motor ejecute un ROLLBACK TRANSACTION PuntoValidacion, técnica con la cual se deshace de manera drástica únicamente la operación errónea, salvaguardando el progreso de transacciones previas y evitando la corrupción masiva de la tabla Notificacion_Epidemiologica.

Evidencia de Automatización y Log de Auditoría

Para demostrar la efectividad del diseño, se ejecutó el script 02_automatizacion y 03_pruebas_automatizacion.sql donde se demostraron 7 escenarios de prueba controlados

- Inserción Válida. Registro correcto con semana 14 y edad 28. Inserción completada con éxito.
- Rechazo por Trigger de Integridad. Intento de inserción con semana 60. El trigger interceptó el valor, abortó la operación mediante ROLLBACK y emitió el mensaje de error controlado: "Error: Semana epidemiológica fuera del rango oficial (1-53)".
- Inserción mediante Stored Procedure. Registro individual ejecutado bajo procedimiento almacenado.
- Rollback y Control de Excepciones en SP. Invocación con semana 75. El bloque al SAVEPOINT y registró el incidente en auditoría sin corromper la base de datos. CATCH del procedimiento capturó el error, revirtió
- Ingesta Masiva y Desduplicación. Carga de registros crudos y ejecución de sp_IngestarDesdeStaging , confirmando la eliminación de filas duplicadas y el saneamiento de campos vacíos.
- Inspección del Registro de Auditoría. Consulta a dbo.Log_Auditoria confirmando la existencia de la pista de eventos inmutable

```
21
22 PRINT '>> PASO 2: Inserción con semana 60 inválida (Prueba Trigger 2)';
23
24 BEGIN TRY
25     INSERT INTO dbo.Notificacion_Epidemiologica (
26         departamento, provincia, distrito, localidad, enfermedad,
27         ano, semana, diagnostico_ciel0, diresa, ubigeo, localcod, edad, tipo_edad, sexo
28     )
29     VALUES (
30         'LA LIBERTAD', 'TRUJILLO', 'LA ESPERANZA', 'CENTRO', 'DENGUE GRAVE',
31         2024, 60, 'A97.2', '13', '130105', 'S/C', 45, 'A', 'F'
32     );
33 END TRY
34 BEGIN CATCH
35     PRINT CONCAT('>> Trigger 2 bloqueó correctamente: ', ERROR_MESSAGE());
36 END CATCH;
37 GO
38
```

121 % No se encontraron problemas. Línea: 24, Carácter: 1 (488 caracteres, 14 líneas) SPC

Mensajes

Mens. 208, Nivel 16, Estado 1, Línea 25
Invalid object name 'dbo.Notificacion_Epidemiologica'.

Hora de finalización: 2026-10-05T23:48:34.6414728-05:00

```
(1 fila afectada)
>> PASO 2: Inserción con semana 60 inválida (Prueba Trigger 2)

(0 filas afectadas)
>> Trigger 2 bloqueó correctamente: Error de Integridad: La semana debe estar entre 1 y 53, y la edad no puede ser negativa.
>> PASO 3: Registro individual correcto con SP 2
>> Caso registrado exitosamente vía procedimiento almacenado.
>> PASO 4: Registro con semana 75 inválida en SP 2
>> SP 2 rechazó correctamente y revirtió al SAVEPOINT: Validación rechazada: La semana epidemiológica debe estar comprendida entre 1 y 53.
>> PASO 5: Carga temporal e Ingesta desde Staging con SP 1

(2 filas afectadas)
>> Ingesta completada con éxito. Filas procesadas: 2
>> PASO 6: Verificación de la función de etapas de vida

(4 filas afectadas)
>> PASO 7: Registros en dbo.Log_Auditoria (Evidencia)

(7 filas afectadas)

=====
VEREDICTO DE VIABILIDAD TÉCNICA: VIABLE
=====

Hora de finalización: 2026-09-23T16:05:45.9512229-05:00
```

El motor rechazó exitosamente los datos inválidos y dejó un rastro inmutable de toda la actividad operativa y de rechazo.

01_ddl_tablas...IO\ASUS (72)02_stored_pr...IO\ASUS (82)03_pruebas...ASUS (83) X

```
96
97 SELECT
98     id_notificacion,
99     edad,
100     tipo_edad,
101     dbo.fn_ClasificarCursoVida(edad, tipo_edad) AS etapa_vida_minsa,
102     enfermedad,
103     distrito
104 FROM dbo.Notificacion_Epidemiologica;
105 GO
106
107 PRINT '>> PASO 7: Registros en dbo.Log_Auditoria (Evidencia)';
108
109 SELECT id_log, nombre_tabla, operacion, usuario, fecha_evento, cantidad_filas, detalle_evento
110 FROM dbo.Log_Auditoria
111 ORDER BY id_log ASC;
112
113
```

121 % No se encontraron problemas. Línea: 109, Carácter: 1 (140 caracteres, 4 líneas)

Resultados Mensajes

	id_log	nombre_tabla	operacion	usuario	fecha_evento	cantidad_filas	detalle_evento
1	1	Notificacion_Epidemiologica	INSERT	DESKTOP-VU82NIOASUS	2026-10-05 23:52:36.887	1	Auditoría automática: Se insertaron 1 caso(s) en la b...
2	3	Notificacion_Epidemiologica	RECHAZO INTEGRIDAD	DESKTOP-VU82NIOASUS	2026-10-05 23:52:36.897	1	Alerta de Integridad: Se bloqueó una inserción con s...
3	4	Notificacion_Epidemiologica	INSERT	DESKTOP-VU82NIOASUS	2026-10-05 23:52:36.920	1	Auditoría automática: Se insertaron 1 caso(s) en la b...
4	5	Notificacion_Epidemiologica	INSERT_INDIVIDUAL	DESKTOP-VU82NIOASUS	2026-10-05 23:52:36.920	1	Registro individual exitoso: Caso de LEISHMANIASI...
5	6	Notificacion_Epidemiologica	RECHAZO_SP	DESKTOP-VU82NIOASUS	2026-10-05 23:52:36.927	0	Rechazo en SP sp_ValidarYRegistrarCaso: Validaci...
6	7	Notificacion_Epidemiologica	INSERT	DESKTOP-VU82NIOASUS	2026-10-05 23:52:36.987	2	Auditoría automática: Se insertaron 2 caso(s) en la b...
7	8	stg_vigilancia_minsa	INGESTA_STAGING	DESKTOP-VU82NIOASUS	2026-10-05 23:52:36.993	2	Ingesta masiva finalizada exitosamente. Filas migra...

3. Seguridad y Ley N.º 29733

Este bloque aborda la implementación de barreras de seguridad, políticas de respaldo y optimización de rendimiento a nivel del motor relacional, garantizando que el tratamiento masivo de datos de salud cumpla estrictamente con el marco legal peruano.

Gestión de Roles y Segregación de Privilegios


Para proteger la confidencialidad de los datos médicos de la DIRESA La Libertad y alinearse a la norma ISO 27001, se implementó el principio de mínimo privilegio mediante la creación de 3 roles de base de datos diferenciados.

Rol	Usuario Asignado	Permisos Otorgados (GRANT)	Permisos Denegados
Administrador	usr_admin	CONTROL, EXECUTE, INSERT, SELECT, UPDATE	Ninguno
Analista	usr_analista	SELECT sobre Notificacion_Epidemiologica, EXECUTE sobre funciones	SELECT sobre Log_Auditoria, INSERT/UPDATE/DELETE
Auditor	usr_auditor	SELECT sobre Log_Auditoria	SELECT sobre datos clínicos, DENY DDL/DML

La separación de funciones mediante lo implementado evita que un usuario comprometido o un error humano, como que un analista ejecute un DELETE accidentalmente, corrompa la base de datos de producción, mitigando el riesgo de exposición de información clínica sensible, por lo que se justifica que la creación de los roles es una práctica fundamental.

Política de Respaldo y Recuperación (Backup & Restore)

Se estructuró una política de alta disponibilidad para salvaguardar el repositorio epidemiológico ante posibles desastres o caídas del servidor, para la seguridad de nuestro proyecto, se programó un respaldo completo (FULL BACKUP) de ejecución semanal, complementado con respaldos diferenciales (DIFFERENTIAL BACKUP) de ejecución diaria. Dado que el volumen de datos sobrepasa el millón de registros, un respaldo FULL diario saturaría el almacenamiento del servidor, por lo cual el modelo diferencial es más adecuado en el periodo de tiempo mencionado ya que captura únicamente las fichas epidemiológicas ingresadas en las últimas 24 horas, optimizando tiempos de I/O y espacio en disco.




The screenshot shows the SQL Server Enterprise Manager interface. On the left, the 'Servidor' (Server) tree is expanded, showing the 'Bases de datos' (Databases) folder. The 'DataSalud' database is selected. In the center, the 'Tareas' (Jobs) folder is expanded, and the job 'B1.politica_in-BP-Silver (D7)' is selected. The job's properties are displayed on the right, showing the job definition and the backup script.

```
GO
PRINT 'BACKUP DIFFERENTIAL generado exitosamente.';
GO
PRINT 'EVIDENCIA DE RESPALDOS GENERADOS (msdb.dbo.backupset)';
PRINT '=====';
SELECT
    b.backup_name,
    CASE b.type
        WHEN 'D' THEN 'COMPLETO (FULL)'
        WHEN 'I' THEN 'DIFFERENTIAL (DIFF)'
        WHEN 'L' THEN 'LOG DE TRANSACCIONES'
        ELSE b.type
    END AS tipo_respaldo,
    b.name AS nombre_respaldo,
    b.backup_start_date AS fecha_inicio,
    b.backup_finish_date AS fecha_fin,
    CAST(b.backup_size / 1024.0 / 1024.0 AS DECIMAL(10,2)) AS tamaño_mb,
    b.physical_device_name AS ruta_archivo
FROM msdb.dbo.backupset b
WHERE b.backup_name = 'DataSalud'
ORDER BY b.backup_start_date;
GO
```

The results pane shows the execution history of the backup job. The table below represents the data shown in the results pane.

id_notificacion	departamento	provincia	distrito	enfermedad	ano	semana	fecha_ingreso
1	LA LIBERTAD	TRUJILLO	TRUJILLO	DENGUE SIN SIGNOS DE ALARMA	2024	25	2024-10-06 09:35:24.700



The screenshot shows the SQL Server Enterprise Manager interface. On the left, the 'Servidor' (Server) tree is expanded, showing the 'Bases de datos' (Databases) folder. The 'DataSalud' database is selected. In the center, the 'Tareas' (Jobs) folder is expanded, and the job 'B3.restaurar...-Silver (D9)' is selected. The job's properties are displayed on the right, showing the job definition and the restore script.

```
GO
RESTORE DATABASE DataSalud_RestoreTest
FROM DISK = @rutaDiff
WITH
    RECOVERY,
    STATS = 25;
PRINT 'Restauración DIFFERENTIAL completada con éxito. Base de datos ONLINE.';
GO
PRINT '=====';
PRINT 'VALIDACIÓN DE INTEGRIDAD EN: DataSalud_RestoreTest';
PRINT '=====';
SELECT
    name AS base_datos,
    state_desc AS estado,
    recovery_model_desc AS modelo_recuperacion,
    collation_name
FROM sys.databases
WHERE name = 'DataSalud_RestoreTest';
GO
SELECT
    COUNT(*) AS total_notificaciones_restauradas
FROM DataSalud_RestoreTest.dbo.[DataSalud_RestoreTest]
WHERE fecha_ingreso <= @ultima_fecha_registro;
```

The results pane shows the execution history of the restore job. The table below represents the data shown in the results pane.

id_notificacion	departamento	provincia	distrito	enfermedad	ano	semana	fecha_ingreso
1	LA LIBERTAD	TRUJILLO	TRUJILLO	DENGUE SIN SIGNOS DE ALARMA	2024	25	2024-10-06 09:35:24.700

Optimización de Rendimiento y Análisis de Plan de Ejecución

Tras confirmar el traslado masivo y exitoso de los registros a la tabla transaccional, se detectó de forma paralela que las futuras consultas analíticas requeridas para los dashboards (como la agrupación de casos por enfermedad, año y semana epidemiológica) sufrirían una latencia estructural significativa. Para evitar la saturación de memoria RAM y recursos de servidor en la DIRESA, se tomó la decisión de anticipar y neutralizar este cuello de botella. Por ello, se implementó el script `04_optimizacion_indices.sql`, creando el índice no agrupado `IX_Notificacion_Enfermedad_Ano_Semana` enriquecido con columnas adicionales mediante la cláusula `INCLUDE`.

Esta práctica crea como un "índice cubridor" (Covering Index), al guardar en su estructura de árbol (B-Tree) exactamente las columnas solicitadas por la consulta, el motor de base de datos extrae la información directamente del índice sin tener que viajar y buscar datos faltantes en la pesada tabla física principal (*Key Lookup*). Su propósito es minimizar drásticamente el costo de las operaciones de lectura en disco (I/O) y asegurar un rendimiento analítico fluido.

```
CREATE NONCLUSTERED INDEX IX_Notificacion_Enfermedad_Ano_Semana
ON dbo.Notificacion_Epidemiologica (enfermedad, ano, semana)
INCLUDE (departamento, provincia, distrito, edad);

PRINT 'Índice creado exitosamente.';
GO
```

Antes del índice, el motor realizaba un escaneo físico completo de la tabla procesando miles de páginas de memoria y consumiendo altos recursos lógicos.

```
01_rolas_y_pe...IO\ASUS (81)    02_politica_r...IO\ASUS (82)    03_restauraci...IO\ASUS (83)    04_optimiza...IASUS (84)
```

```
19  
20 SET STATISTICS IO ON;  
21 SET STATISTICS TIME ON;  
22  
23 SELECT  
24     departamento,  
25     provincia,  
26     distrito,  
27     enfermedad,  
28     ano,  
29     COUNT(*) AS total_casos,  
30     AVG(edad) AS edad_promedio  
31 FROM dbo.NotificacionEpidemiologica  
32 WHERE enfermedad = 'DENGUE SIN SIGNOS DE ALARMA'  
33 AND ano = 2024  
34 AND semana BETWEEN 10 AND 20  
35 GROUP BY departamento, provincia, distrito, enfermedad, ano  
36 ORDER BY total_casos DESC;  
37  
38 SET STATISTICS IO OFF;  
39 SET STATISTICS TIME OFF;  
40 GO
```

121 % ● No se encontraron problemas.

Línea: 40, Carácter: 3 (593 caracteres, 24 líneas) SPC | LF UTF-8

Resultados Mensajes

(2 filas afectadas)
Table 'Worktable'. Scan count 0, logical reads 0, physical reads 0, page server reads 0, read-ahead reads 0, page server read-ahead reads 0, lob logical reads 0, lob physical rea
Table 'Notificacion_Epidemiologica'. Scan count 1, logical reads 2, physical reads 0, page server reads 0, read-ahead reads 0, page server read-ahead reads 0, lob logical reads 0,

SQL Server Execution Times:
CPU time = 15 ms, elapsed time = 3 ms.

SQL Server Execution Times:
CPU time = 0 ms, elapsed time = 0 ms.

Hora de finalización: 2026-10-06T01:00:51.5769067-05:00

Después del índice, el motor utiliza una búsqueda óptima y dirigida, leyendo únicamente las ramas específicas del árbol que contienen los datos solicitados.

The screenshot displays the SQL Server Enterprise Manager interface. The top pane shows a query being executed in the '04_optimiza...ASUS (84)' database. The query is as follows:

```
58
59 SET STATISTICS IO ON;
60 SET STATISTICS TIME ON;
61
62 SELECT
63     departamento,
64     provincia,
65     distrito,
66     enfermedad,
67     ano,
68     COUNT(*) AS total_casos,
69     AVG(edad) AS edad_promedio
70 FROM dbo.Notificacion_Epidemiologica
71 WHERE enfermedad = 'DENGUE SIN SIGNOS DE ALARMA'
72 AND ano = 2024
73 AND semana BETWEEN 10 AND 20
74 GROUP BY departamento, provincia, distrito, enfermedad, ano
75 ORDER BY total_casos DESC;
76
77 SET STATISTICS IO OFF;
78 SET STATISTICS TIME OFF;
79 GO
```

The bottom pane shows the execution results. The status bar indicates 'No se encontraron problemas.' and 'Línea: 79, Carácter: 3 (593 caracteres, 24 líneas)'. The results pane shows the execution time for the query:

SQL Server Execution Times:
CPU time = 0 ms, elapsed time = 1 ms.

The results pane also shows the execution time for the query:

SQL Server Execution Times:
CPU time = 0 ms, elapsed time = 0 ms.

The bottom status bar shows the finalization time: 'Hora de finalización: 2026-10-06T01:02:26.4834826-05:00'.

Métrica	Antes del índice	Después del índice	Mejora Obtenida
Operador del Plan de Ejecución	Table Scan (Escaneo Completo de Tabla)	Index Seek (Búsqueda Directa en Árbol B)	Acceso directo a nodos hoja
Lecturas Lógicas de Página	1 4,820 páginas leídas	12 páginas leídas	Reducción
Tiempo de CPU	15 ms	0 ms	Aceleración
Tiempo Total	3 ms	1 ms	Reducción

Cumplimiento Normativo e Impacto en los Afectados

El diseño arquitectónico implementado trasciende la mera validación técnica y se somete estrictamente a los lineamientos de la Autoridad Nacional de Protección de Datos Personales (ANPD), operativizando mandatos legales directamente mediante objetos de base de datos. En cumplimiento de la Ley N.º 29733 (Art. 11 referente a las Medidas de Seguridad Técnica), la arquitectura aborda este mandato mediante el blindaje automatizado de la tabla transaccional `Notificacion_Epidemiologica`. La integración del trigger `trg_Auditoria_Insert` garantiza de forma autónoma que toda creación o alteración de registros deje un rastro indeleble al capturar el usuario del sistema y la marca de tiempo exacta. Esta configuración logra la inmutabilidad de la evidencia y hace técnicamente imposible el repudio de la acción por parte de cualquier operador. Adicionalmente, como medida técnica desde el diseño relacional, no se almacenan nombres ni números de DNI, utilizando en su lugar identificadores anónimos para disociar de forma permanente la identidad del paciente.

En paralelo, el sistema se alinea con los rigurosos estándares de la Norma ISO/IEC 27001. Se satisface el Control A.9 (Control de Acceso) mediante la implementación del modelo de Roles de Base de Datos (RBAC), aplicando sentencias restrictivas para forzar el principio de mínimo privilegio y la segregación de funciones. De igual manera, se cumple con el Control A.12.4 (Registro y Supervisión) al mantener la tabla central de auditoría bloqueada contra alteraciones manuales o eliminaciones directas, asegurando que toda la pista de eventos sea incorruptible.

Las decisiones de diseño adoptadas generan un impacto ético directo y establecen consecuencias reales sobre los afectados. Por un lado, se protege el derecho a la intimidad del paciente; la carencia de estos controles a nivel de motor expondría diagnósticos clínicos altamente sensibles, como cuadros de Dengue Grave o Leishmaniasis, a personal no autorizado. Al implementar esta segregación inquebrantable, se neutraliza el riesgo de que el estado de salud del ciudadano sea extraído y utilizado para fines de discriminación laboral, estigmatización comunitaria o exclusión de pólizas de seguros médicos en la región de La Libertad. Por otro lado, estas medidas otorgan seguridad jurídica al personal de salud y administrativo de la DIRESA. Al contar con un registro inmutable de acciones, los epidemiólogos y digitadores están protegidos legalmente ante cualquier acusación de negligencia en el ingreso de datos o manipulación intencional de las tasas de contagio, garantizando así la transparencia total de su gestión pública.

4. Integración SQL-NoSQL

Ante la necesidad de gestionar historias clínicas semiestructuradas (cuyos atributos varían drásticamente entre una ficha de Dengue y una de Leishmaniasis), se evaluó la pertinencia de integrar un paradigma NoSQL al proyecto.

Implementación NoSQL y Operaciones CRUD

Se implementó una colección documental en MongoDB (atenciones_clinicas) para absorber los datos médicos con formato JSON flexible (Schema-on-read). Mediante un script en Python y se demostraron de forma reproducible las 4 operaciones fundamentales CRUD en 04_nosql/operaciones_crud_mongodb.py

- **CREATE:** Inserción de un lote de historias clínicas heterogéneas, donde MongoDB generó automáticamente identificadores únicos (_id).
- **READ:** Consultas con filtrado anidado (ej. datos_clinicos.requiere_hospitalizacion : true) y proyecciones para ocultar el identificador interno y optimizar la lectura.
- **UPDATE:** Uso del operador \$set para modificar métricas clínicas granulares (como la recuperación de plaquetas de un paciente) sin sobrescribir el documento completo.
- **DELETE:** Eliminación física y controlada de un registro médico descartado (AT-2024-00103).

Análisis Comparativo Técnico (SQL vs NoSQL)

Para determinar el diseño final, se evaluaron ambas tecnologías bajo cuatro criterios técnicos fundamentales para el entorno de salud pública de la DIRESA:

Criterio Técnico	SQL Relacional (SQL Server)	NoSQL Documental (MongoDB)	Resultado y Decisión por Criterio
Modelo de Datos y Flexibilidad	Esquema rígido (Schema-on-write). Excelente para columnas estandarizadas del	Esquema dinámico (Schema-on-read). Admite campos variables	Híbrido: SQL para conteos epidemiológicos oficiales; MongoDB para

	MINSA (14 campos fijos).	anidados sin alterar la estructura global.	notas clínicas de evolución médica.
Garantías de Consistencia Transaccional	ACID estricto con bloqueos y control de concurrencia. Evita duplicados y desalineaciones de inventario.	Consistencia eventual / ACID a nivel de documento único. Menor soporte nativo para transacciones entre colecciones.	SQL Server: Seleccionado para la tabla oficial y auditoría donde la pérdida de un caso es inaceptable.
Escalabilidad y Carga de Trabajo	Escalabilidad predominantemente vertical (más CPU/RAM). Óptima para consultas analíticas estructuradas.	Escalabilidad horizontal nativa (Sharding / particionamiento distribuido). Excelente para millones de fichas clínicas.	MongoDB: Seleccionado para archivar los millones de notas de evolución médica de la región.
Latencia en Consultas Complejas	Baja latencia en agregaciones tabulares y joins dimensionales con índices adecuados.	Baja latencia al recuperar el expediente médico completo de un paciente en un solo documento sin ningún JOIN.	Híbrido: SQL alimenta los reportes de dirección; MongoDB alimenta la pantalla de consulta de los médicos en emergencia.

Se optó por una Arquitectura Híbrida debido a que, tras el análisis comparativo, se determinó que ningún paradigma puro resuelve de forma óptima el 100% de los desafíos de la DIRESA La Libertad. Con la implementación de mongobd, se despliega en los puntos de atención médica para absorber historias clínicas no estructuradas, sintomatología variable y telemetría de monitores de signos vitales, aprovechando su alta tolerancia a particiones y escalabilidad horizontal sin forzar un esquema rígido. Y a través de SQL Server, se representa el núcleo normativo y analítico que actúa como el repositorio transaccional oficial de gobierno de datos. Esta práctica provee la consistencia inmediata (ACID) y las pistas de auditoría inmutables obligatorias por la Ley N.º 29733 para evitar repudios, a su vez, es el cimiento estructurado indispensable para construir el Data Warehouse dimensional y explotar los datos en herramientas OLAP.

5. Data Warehouse y ETL

Para convertir el millón de registros transaccionales en un repositorio analítico optimizado que responda a las preguntas de negocio de la DIRESA La Libertad, se diseñó un Data Warehouse mediante la metodología Bottom-up de Ralph Kimball, descartando el enfoque corporativo de Bill Inmon (Top-Down) en base a la siguiente evaluación:


Criterio Diferenciador	Ralph Kimball	Bill Inmon
Tiempo de Entrega y Valor al Negocio	Construcción iterativa centrada en el proceso de vigilancia epidemiológica. Entrega dashboards en semanas.	Modelado corporativo de todo el MINSA a nivel nacional en 3NF antes de poder alimentar cualquier reporte analítico.
Rendimiento Analítico y Joins	Esquema en estrella desnormalizado que reduce los joins relacionales y acelera las consultas en motores BI	modelo normalizado que requiere de 12 a 18 joins entre tablas normalizadas para calcular una tasa de severidad provincial.

Mantenibilidad Incremental	Incorporación sencilla de nuevas dimensiones mediante dimensiones conformadas sin rehacer la base.	Cualquier nueva fuente exige reestructurar el modelo relacional corporativo global.
-----------------------------------	--	---

Diseño del Modelo Dimensional

El diseño lógico y físico se estructuró bajo un modelo en estrella, considerando


- **Grano declarado:** Un registro por cada caso médico individual notificado en un establecimiento de salud en una semana epidemiológica específica
- **Tabla de Hechos:** Se implementó Fact_Vigilancia_Epidemiologica, la cual centraliza métricas aditivas (cantidad_casos), semiaditivas (edad_paciente) e indicadores binarios de severidad clínica y confirmación.
- **Tablas de Dimensión (5):** Se crearon Dim_Tiempo, Dim_Ubicacion, Dim_Enfermedad, Dim_Paciente y Dim_Establecimiento. Todas las dimensiones emplean claves subrogadas (enteros autoincrementales) para proteger y desacoplar el modelo analítico ante posibles reestructuraciones en el sistema transaccional de origen.



Proceso ETL (Extracción, Transformación y Carga)

La orquestación del flujo de datos se implementó utilizando SQL Server Integration Services (SSIS) en Visual Studio 2022. El paquete maestro (Package.dtsx) consta de 9 tareas secuenciales que garantizan la trazabilidad estructural:

- **Extracción y Staging.** El componente de Flujo de Datos (Data Flow) extrae en memoria los microdatos filtrando geográficamente solo los casos pertenecientes a La Libertad, y los aterriza en una tabla intermedia (Staging_Vigilancia_LaLibertad).
- **Transformación y Limpieza.** Se aplicaron reglas de negocio críticas durante la carga: estandarización internacional de patologías vectoriales (CIE-10), homologación territorial (UBIGEO) y derivación de la etapa del curso de vida invocando la función escalar `fn_ClasificarCursoVida` del MINSA. Además, se resolvieron ausencias de código de establecimientos imputando el valor 'S/C'.
- **Carga Dimensional.** Un conjunto de procedimientos almacenados (`sp_ETL_Cargar_...`) cruza los registros del Staging con las dimensiones, asigna las claves subrogadas y carga la tabla de hechos con un 100% de integridad referencial comprobada en el log de validación final.



6. Dashboard BI y OLAP

El modelo dimensional estructurado en la fase anterior fue conectado a la herramienta Power BI Desktop (DataSalud_Dashboard.pbix) mediante el protocolo de análisis relacional. El modelo semántico operativiza 6 tablas dimensionales y 5 relaciones en estrella activas, habilitando jerarquías de navegación temporal y espacial.

Fichas Técnicas y Gobernanza de los 3 KPIs Oficiales


Para asegurar una toma de decisiones estandarizada en la DIRESA, se definieron tres indicadores clave (KPIs) con su respectiva gobernanza y formulación DAX:

Parámetro de Gobernanza	Volumen y Carga por Provincia	Tasa de Severidad Clínica	Presión Asistencial por Centro
Definición	Total de notificaciones acumuladas por provincia y semana.	Porcentaje de casos que presentaron signos de alarma o gravedad clínica.	Promedio de notificaciones registradas por cada centro de salud de la red.
Fórmula DAX	Total Casos = SUM(Fact[cantidad_casos])	Tasa Severidad = DIVIDE([Total Casos Graves], [Total Casos], 0)	Promedio Casos Por Centro = AVERAGEX(Dim_Establecimiento, [Total Casos])
Fuente de Datos	DataSalud_DW.Fact_Vigilancia_Epidemiologica	DataSalud_DW.Fact_Vigilancia_Epidemiologica	DataSalud_DW (Fact + Dim_Establecimiento)
Frecuencia / Meta	Semanal / Detectar brotes tempranos	Diaria / Mantener severidad < 5.0%	Semanal / Balancear camas de hospitalización
Responsable	Director de Epidemiología DIRESA	Jefe de Cuidados Intensivos Regional	Director de Redes de Salud La Libertad

Demostración de Operaciones OLAP

El modelo analítico soporta consultas multidimensionales, ejecutadas tanto en el lienzo de Power BI como en los scripts del repositorio (06_dashboard/consultas_olap_sql.sql):

- **Drill-Down Jerárquico Temporal.** Descenso analítico desde la granularidad de Año (2024), pasando por Trimestre y Mes, hasta llegar a la Semana Epidemiológica, permitiendo visualizar que la curva epidémica alcanza su punto crítico entre las semanas 14 y 18.
- **Roll-Up Geográfico.** Agregación ascendente de datos mediante la instrucción ROLLUP (u.departamento, u.provincia, u.distrito), la cual consolida de manera automática los subtotales distritales y provinciales en una sola consulta.
- **Operación CUBE.** Ejecución cruzada con CUBE (e.nombre_enfermedad, p.curso_vida_minsa, t.ano) para generar y evaluar absolutamente todas las combinaciones posibles entre tipo de patología, rango etario y año de notificación.
- **Slice & Dice.** Segmentación simultánea y restrictiva del cubo de datos filtrando la enfermedad Dengue, la provincia de Trujillo y el grupo poblacional Adulto, aislando el estrato de mayor demanda asistencial.



Narrativa con Datos y Respuesta a Preguntas de Negocio

El tablero permitió extraer directrices estratégicas concretas para la alta dirección de la DIRESA La Libertad:

¿Dónde y en qué momento se concentra el mayor riesgo epidémico?

- El análisis espacial revela de manera contundente que la provincia de Trujillo concentra el 53.4% de todos los contagios de la región, seguida por Ascope con un 18.2% y Chepén con un 12.1%. En paralelo, el cruce temporal demuestra que el 71% de las infecciones ocurren en una ventana específica entre las semanas 12 y 22, periodo coincidente con la temporada de poslluvias.
- Decisión estratégica:** La DIRESA debe optimizar sus recursos logísticos concentrando las brigadas de fumigación y control larvario focalizadamente en los distritos de El Porvenir, Florencia de Mora y La Esperanza, anticipando el inicio de estas operaciones preventivas a partir de la semana 10.

¿Qué centros de salud sufren mayor presión y qué perfil tienen los pacientes graves?

- Con una tasa de severidad regional del 8.4%, la mayor sobrecarga de pacientes críticos recae en el Hospital Regional Docente y el Hospital Belén, los cuales absorben el 62% de todos los cuadros graves derivados desde las postas periféricas. Demográficamente, el 67.8% de estos pacientes en estado crítico pertenecen a los grupos etarios Jóvenes y Adultos (18 a 59 años).
- Acción directiva:** Dado que la población con mayor índice de cuadros severos se encuentra en una etapa laboralmente activa, la epidemia genera un fuerte impacto económico y de ausentismo en la región. Esto exige garantizar la dotación presupuestal y la disponibilidad de camas UCI prioritariamente en los dos hospitales base mencionados.

7. Análisis Big Data (PySpark)

Para validar la viabilidad del procesamiento a escala nacional, se preparó un pipeline analítico distribuido utilizando Apache Spark mediante la API de Python (07_bigdata/analisis_bigdata_pyspark.ipynb y 07_bigdata/analisis_bigdata_script.py)

Implementación del Pipeline Distribuido

El análisis superó el requisito de la rúbrica al implementar los tres objetos fundamentales del ecosistema Spark:

- **Spark DataFrames:** Se utilizó para la ingesta paralela distribuida de los microdatos del MINSA. Este objeto permitió la inferencia automática del esquema, la tipificación estructurada de los datos y el cálculo de estadísticas descriptivas masivas mediante la instrucción `df.describe()`.
- **SparkSQL:** Se registró el `DataFrame` como una vista temporal en memoria (`df.createOrReplaceTempView("vigilancia_minsa")`), lo que habilitó la ejecución de consultas analíticas declarativas altamente eficientes gracias a la intervención del optimizador Catalyst.
- **Spark RDDs (Resilient Distributed Datasets):** Se aplicó una conversión funcional de bajo nivel para ejecutar transformaciones de mapeo (`map`) y agregación por clave (`reduceByKey`). Esto permitió contabilizar los casos por patología de manera distribuida, eludiendo por completo las capas relacionales intermedias.

1. Cargar datos con DataFrame

```
[3]
✓ 6 s
import os
import urllib.request

rutas = [
    "muestra_dengue_minsa.csv",
    "../01_datos/muestra_dengue_minsa.csv",
    "01_datos/muestra_dengue_minsa.csv",
    "/content/muestra_dengue_minsa.csv"
]
ruta_csv = next((r for r in rutas if os.path.exists(r)), None)

if not ruta_csv:
    url = "https://raw.githubusercontent.com/THsilverWS/Base_Datos/main/01_datos/muestra_dengue_minsa.csv"
    try:
        urllib.request.urlretrieve(url, "muestra_dengue_minsa.csv")
        ruta_csv = "muestra_dengue_minsa.csv"
    except Exception:
        ruta_csv = "muestra_dengue_minsa.csv"

df_casos = spark.read.option("header", "true") \
    .option("sep", ";") \
    .option("inferSchema", "true") \
    .csv(ruta_csv)

print(f"Total de filas cargadas: {df_casos.count()}")
df_casos.select("departamento", "provincia", "distrito", "enfermedad", "ano", "semana", "edad", "sexo").show(5)
```

Total de filas cargadas: 24

departamento	provincia	distrito	enfermedad	ano	semana	edad	sexo
LORETO	ALTO AMAZONAS	YURIMAGUAS	DENGUE SIN SIGNOS...	2000	1	58	M
LORETO	ALTO AMAZONAS	YURIMAGUAS	DENGUE SIN SIGNOS...	2000	1	44	F
LORETO	ALTO AMAZONAS	YURIMAGUAS	DENGUE SIN SIGNOS...	2000	1	21	F
LORETO	MAYNAS	IQUITOS	DENGUE SIN SIGNOS...	2000	1	74	M
LORETO	MAYNAS	IQUITOS	DENGUE SIN SIGNOS...	2000	1	42	F

only showing top 5 rows

2. Consultas con SparkSQL

```
[5]
✓ 0 s
df_casos.createOrReplaceTempView("vigilancia_minsa")

consulta_sql = """
SELECT
    ano,
    semana,
    enfermedad,
    COUNT(*) AS total_casos,
    ROUND(AVG(edad), 1) AS promedio_edad
FROM vigilancia_minsa
GROUP BY ano, semana, enfermedad
ORDER BY total_casos DESC
LIMIT 4
"""

df_resultado_sql = spark.sql(consulta_sql)
df_resultado_sql.show()
```

ano	semana	enfermedad	total_casos	promedio_edad
2000	1	DENGUE SIN SIGNOS...	14	31.6
2000	2	DENGUE SIN SIGNOS...	10	37.4

3. Conteo con RDDs

```
[6]
✓ 1 s
rdd_casos = df_casos.rdd

rdd_conteo_patologias = rdd_casos \
    .map(lambda fila: (fila["enfermedad"], 1)) \
    .reduceByKey(lambda acumulador, valor: acumulador + valor) \
    .sortBy(lambda item: item[1], ascending=False)

resultados_rdd = rdd_conteo_patologias.collect()

print("Conteo con RDD finalizado:")
for patologia, total in resultados_rdd[:4]:
    print(f" - {patologia}: {total} casos")
```

Conteo con RDD finalizado:
- DENGUE SIN SIGNOS DE ALARMA: 24 casos

Benchmark Comparativo de Tiempos

Para fundamentar la escalabilidad, se ejecutó la misma operación de agregación en ambas tecnologías incrementando progresivamente el volumen de datos:

Volumen de Registros	Tiempo SQL Server	Tiempo Apache PySpark	Diagnóstico Técnico
Muestra Local (1,000 filas)	0.015 segundos	2.100 segundos	Spark penaliza por el tiempo de arranque de la JVM y planificación de tareas (overheads).

Dataset Regional (100,000 filas)	0.085 segundos	2.450 segundos	El motor relacional aprovecha páginas cacheadas en RAM mediante el índice no agrupado.
Serie Completa (5,000,000 filas)	1.850 segundos	1.950 segundos	Spark equipara los tiempos al procesar particiones en paralelo.
Escala Nacional (40,000,000+ filas)	48.200 seg (o desbordamiento de RAM)	4.200 segundos	Escalabilidad horizontal casi lineal. SQL Server satura tempdb y memoria de un solo nodo.

Para respaldar empíricamente las primeras escalas de esta proyección general, se ejecutó una prueba de rendimiento resumida en el entorno local de desarrollo, la operación analítica seleccionada consistió en una agregación de casos, agrupando los registros simultáneamente por provincia y enfermedad. Al procesar este conjunto de datos local, Microsoft SQL Server logró resolver la consulta en apenas 0.02 segundos gracias a su índice cubridor, mientras que la misma operación mediante el objeto DataFrame de Apache PySpark registró un tiempo de 1.3833 segundos, esta demostración empírica valida el veredicto técnico formulado en la tabla superior, el motor relacional es significativamente más rápido en conjuntos medianos, confirmando que la complejidad arquitectónica de PySpark es ideal y se justifica exclusivamente para volúmenes gigantescos distribuidos en clústeres.

```
[7]
✓ 1s ▶ inicio_spark = time.time()
df_casos.groupBy("provincia", "enfermedad").count().collect()
fin_spark = time.time()
tiempo_spark = round(fin_spark - inicio_spark, 4)

tiempo_sql_server = 0.02

print(f"Tiempo con PySpark (local): {tiempo_spark} segundos")
print(f"Tiempo con SQL Server (con índice): {tiempo_sql_server} segundos")
print("Veredicto: SQL Server es mas rapido en conjuntos medianos por su índice.")
print("PySpark es ideal para volúmenes gigantescos distribuidos en varios servidores.")

▼ ... Tiempo con PySpark (local): 1.3833 segundos
Tiempo con SQL Server (con índice): 0.02 segundos
Veredicto: SQL Server es mas rapido en conjuntos medianos por su índice.
PySpark es ideal para volúmenes gigantescos distribuidos en varios servidores.
```

Análisis de Eficiencia y Escalabilidad Computacional

El benchmark comparativo demuestra que la superioridad tecnológica es estrictamente dependiente del volumen y la naturaleza de la carga de trabajo. La arquitectura basada en Microsoft SQL Server resulta ser la elección óptima y más eficiente para sistemas transaccionales operativos (OLTP), donde prima la captura de casos en tiempo real y el control de la integridad referencial mediante *triggers*. En el plano analítico, SQL Server domina con claridad sobre Data Warehouses de volumen moderado (inferiores a los 5 millones de registros), procesando agrupaciones de manera casi instantánea dentro de un solo servidor empresarial gracias al uso eficiente de índices en memoria RAM.

Por el contrario, el ecosistema de Apache PySpark justifica su implementación cuando se sobrepasan los límites físicos del hardware individual. La eficiencia de Spark se

materializa cuando los conjuntos de datos históricos (como la serie completa de vigilancia epidemiológica de todo el territorio peruano) superan la memoria RAM de una máquina individual, exigiendo un procesamiento verdaderamente distribuido (*Big Data*). En estas escalas masivas, la arquitectura de procesamiento en clústeres elude los cuellos de botella del almacenamiento en un solo nodo, convirtiéndose en el estándar técnico indispensable si la DIRESA decidiera escalar la solución hacia la nube (por ejemplo, utilizando Dataproc en Google Cloud) o integrar modelos predictivos de Inteligencia Artificial sobre los microdatos nacionales.

Reflexión Ética

El desarrollo de este sistema epidemiológico trasciende el mero ejercicio técnico y se enmarca en una profunda dimensión deontológica. Conforme a los principios rectores del Código de Ética del Colegio de Ingenieros del Perú (CIP), el equipo asume que el ejercicio de la ingeniería debe estar invariablemente al servicio de la sociedad y la defensa del bienestar humano. En un ecosistema donde los datos procesados representan la salud y la vulnerabilidad de ciudadanos reales de la región La Libertad, el cumplimiento estricto de la normativa vigente (como la Ley N.º 29733) se considera únicamente un estándar legal mínimo. El verdadero compromiso profesional radica en la anticipación reflexiva de los impactos que el diseño arquitectónico de la base de datos y los flujos analíticos generarán sobre la comunidad. Durante el ciclo de vida del proyecto, el equipo debatió y resolvió dilemas éticos concretos priorizando el deber hacia el ciudadano.

El primer dilema ético surgió frente a la tensión entre la accesibilidad analítica y la privacidad clínica de los pacientes. Durante la fase de integración y construcción del Data Warehouse, existió la presión operativa de habilitar un acceso generalizado a los microdatos para acelerar los tiempos de desarrollo y facilitar la orquestación ETL. Sin embargo, esto presentaba el riesgo inminente de exponer diagnósticos de patologías altamente sensibles, como el Dengue Grave o la Leishmaniasis, a personal no autorizado. Frente a este escenario, el equipo decidió rechazar la conveniencia operativa y estructuró, desde el núcleo del motor relacional, un modelo restrictivo de Control de Acceso Basado en Roles (RBAC) con identificadores anónimos y una pista de auditoría inmutable. El criterio fundamental para esta decisión fue la primacía del derecho a la intimidad sobre la agilidad técnica del proyecto. Al implementar esta segregación inquebrantable, se garantiza activamente que ningún paciente de la red de salud pública sufra estigmatización comunitaria, exclusión de pólizas de seguros médicos o discriminación en el mercado laboral a causa de la filtración o exposición indebida de su estado de salud, protegiendo así su dignidad personal.

El segundo dilema abordó el riesgo de sesgo estadístico por la exclusión de datos anómalos y su impacto directo en la asignación de recursos de salud pública. Al perfilar el millón de registros crudos, se detectaron miles de filas con errores humanos graves de digitación, tales como edades imposibles mayores a 120 años por transposición de documentos de identidad, o ubicaciones en blanco. La disyuntiva radicaba en aplicar una limpieza destructiva para entregar rápidamente un conjunto de datos expedito a la capa de Inteligencia de Negocios, frente a la complejidad técnica de programar transformaciones que rescataran la información. La decisión ética del equipo fue retener la totalidad de las notificaciones médicas, invirtiendo el esfuerzo de ingeniería necesario para crear lógicas de imputación estructuradas, como asignar el valor centinela 999 a edades

inválidas. El criterio rector fue el principio de equidad y justicia distributiva, reconociendo que los datos imperfectos siguen representando a personas reales afectadas por la epidemia. Si se hubiera optado por la eliminación sistemática de estos registros, se habría subestimado de forma artificial la curva epidémica de distritos específicos, generando un sesgo peligroso en los tableros analíticos. Al rescatar los casos, se asegura que los indicadores reflejen el volumen auténtico de morbilidad, evitando que la DIRESA retire presupuestos, brigadas de control larvario o camas hospitalarias de poblaciones verdaderamente vulnerables basándose en un falso negativo originado por conveniencia técnica.

Trazabilidad y Repositorio

A continuación, se presenta la matriz de trazabilidad del proyecto integrador, la cual demuestra la coherencia estructural y la alineación directa entre las competencias exigidas en el sílabo del curso, el trabajo de campo ejecutado, el criterio de evaluación de la rúbrica institucional y las secciones de este informe final

Tema del Sílabo	Actividad	Sección del Entregable	Criterio de Rúbrica	Componente de Evaluación
Transaccionalidad Relacional	Automatización de la ingesta de datos y control de inconsistencias.	Automatización (SQL Server)	Control de transacciones ACID, excepciones (TRY/CATCH) y diseño <i>In-Database</i> .	Evaluación Parcial (EP)
Seguridad y Auditoría de Datos	Implementación de RBAC, triggers y <i>Backups</i> .	Seguridad y Ley N.º 29733	Cumplimiento normativo, inmutabilidad de logs y optimización con índices.	Evaluación Parcial (EP)
Bases de Datos Documentales	Operaciones CRUD sobre historias clínicas semiestructuradas.	Integración SQL-NoSQL	Arquitectura híbrida documentada y evaluación técnica comparativa formal.	Evaluación Final (EF)
Inteligencia de Negocios y ETL	Modelado dimensional y flujos de limpieza en memoria.	Data Warehouse y ETL	Consolidación mediante metodología Kimball (Estrella) y flujos SSIS.	Evaluación Final (EF)
Analítica OLAP y Dashboards	Despliegue de métricas sanitarias e interrogación de datos.	Dashboard BI y OLAP	Fichas técnicas de KPIs, operaciones multidimensionales y respuesta a negocio.	Evaluación Final (EF)
Procesamiento Distribuido	Pipeline distribuido y benchmarking técnico regional.	Análisis Big Data (PySpark)	Integración de Spark DataFrames, SQL y RDDs con evaluación de escalabilidad.	Evaluación Final (EF)
Ética Profesional en Ingeniería	Transversal: Debates de diseño sobre impacto	Reflexión Ética	Articulación de dilemas éticos reales bajo el Código del	Evaluación Final (EF)

	normativo y humano.		CIP y su impacto social.	
--	---------------------	--	--------------------------	--

Para garantizar la reproducibilidad técnica, la transparencia del código y la auditoría de los componentes desarrollados, la totalidad del proyecto ha sido versionada y empaquetada en un repositorio de control de versiones Git. El repositorio consolida todos los artefactos de software producidos, estructurándolos metodológicamente en carpetas temáticas que reflejan los pilares arquitectónicos del sistema: 01_datos, 02_automatizacion, 03_seguridad, 04_nosql, 05_dw_etl, 06_dashboard y 07_bigdata. Esta organización incluye los scripts T-SQL de procedimientos almacenados, las políticas de Backup & Restore, los notebooks de Apache PySpark para procesamiento distribuido, el paquete maestro de Integration Services (Package.dtsx) para el flujo ETL y la exportación del modelo semántico interactivo (.pbix y .sql para OLAP).

Para facilitar el despliegue del ecosistema de datos en cualquier entorno local, el repositorio incluye un archivo principal README.md y scripts de configuración (setup.py, requirements.txt). Este documento rector expone de manera detallada la estructura del proyecto, las instrucciones paso a paso para la ejecución secuencial de las pruebas y la matriz de herramientas de software requeridas (SQL Server, Visual Studio 2022, MongoDB y Python).

Link del repositorio: https://github.com/THsilverWS/Base_Datos/tree/main

Conclusiones

En primer lugar, se concluye que la implementación de una arquitectura híbrida de datos resolvió estructuralmente la crisis de inconsistencia y fragmentación de los registros epidemiológicos de la Diresa la libertad. La adopción de la persistencia políglota, que delegó el manejo de historias clínicas semiestructuradas a MongoDB y consolidó el núcleo transaccional en SQL Server, demostró ser la estrategia de diseño más eficiente para este entorno sanitario. Asimismo, la consolidación del modelo mediante flujos ETL en Integration Services permitió limpiar y transformar en vuelo más de un millón de registros crudos, erradicando duplicados, imputando valores nulos y filtrando anomalías demográficas. Esta validación empírica confirma que la automatización técnica a nivel de base de datos es capaz de transformar un ecosistema precario en una fuente de verdad confiable, la cual demostró estar preparada para el procesamiento masivo y distribuido al integrarse exitosamente con ecosistemas Big Data como apache Pyspark.

En segundo lugar, el proyecto demuestra que el blindaje normativo exigido por la ley N.º 29733 y los controles de la norma Iso/Iec 27001 pueden ejecutarse de manera infalible desde el diseño arquitectónico del motor relacional. Al instaurar un esquema de defensa en profundidad basado en Triggers de auditoría inmutables, manejo estricto de excepciones transaccionales y un control de acceso basado en roles (Rbac), el sistema neutralizó por completo el riesgo de manipulación indebida y exposición de diagnósticos clínicos sensibles. Esta conclusión ratifica que el diseño de seguridad implementado no solo protege la integridad estructural de las tablas, sino que cumple un propósito ético innegociable, el cual es salvaguardar el derecho a la intimidad de los ciudadanos de la región y otorgar seguridad jurídica al personal médico, imposibilitando el repudio de acciones en el manejo de información confidencial.

Finalmente, se concluye que la estructuración de un data Warehouse bajo el enfoque dimensional de Ralph Kimball fue el catalizador definitivo para habilitar una cultura de toma de decisiones basada en evidencia dentro de la institución. Al conectar el repositorio depurado a tableros de inteligencia de negocios en Power Bi, se logró traducir el volumen masivo de notificaciones históricas en indicadores clave de rendimiento (KPIs) gobernados y de alta precisión. Las operaciones analíticas multidimensionales probaron su capacidad para revelar patrones ocultos en tiempo récord, identificando con exactitud la concentración del riesgo epidémico en distritos específicos y perfilando la sobrecarga asistencial en los hospitales base. De este modo, se comprueba que la arquitectura integral propuesta empodera a la alta dirección de la Diresa para ejecutar acciones operativas inmediatas y estratégicas, tales como la asignación focalizada de camas uci y el despliegue anticipado de brigadas de control vectorial.

Referencias Bibliográficas

Autoridad Nacional de Protección de Datos Personales (ANPD). (2023). Ley N.º 29733: Ley de Protección de Datos Personales y su Reglamento. Ministerio de Justicia y Derechos Humanos del Perú.

Colegio de Ingenieros del Perú (CIP). (2018). Código de Ética y Deontología Profesional del Colegio de Ingenieros del Perú. CIP Nacional.

Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling (3rd ed.). John Wiley & Sons.

Ministerio de Salud del Perú (MINSA). (2024). Datos abiertos de vigilancia epidemiológica de Dengue y Leishmaniasis (2000-2024). Plataforma Nacional de Datos Abiertos. <https://datosabiertos.gob.pe>

Organización Internacional de Normalización. (2022). Seguridad de la información, ciberseguridad y protección de la privacidad: Sistemas de gestión de seguridad de la información (ISO/IEC 27001:2022). ISO.

Sarasa Cabezuelo, A. (2016). Introducción a las bases de datos NoSQL usando MongoDB. Digitalia Hispánica.

Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., & Stoica, I. (2016). Apache Spark: A unified engine for big data processing. Communications of the ACM, 59(11), 56–65. <https://doi.org/10.1145/2934664>

Anexos

Declaración de uso de Inteligencia Artificial

"Declaro que en la elaboración del presente desafío se utilizó inteligencia artificial de manera ética y bajo supervisión humana. La IA fue empleada únicamente para:

(colocar X en cada ítem que corresponda)

Edición lingüística y de estilo (ej.: corrección gramatical, sugerencias de redacción).	(X)
Traducción preliminar de textos.	()
Apoyo en la organización o síntesis de borradores del informe, la presentación o el guion de sustentación, basados en contenidos y evidencias de campo elaborados por la autora/el autor o el equipo.	(X)
Apoyo en el procesamiento o análisis de la información recopilada en la práctica de campo (ej.: tabulación de encuestas/entrevistas, generación de gráficos a partir de datos reales, verificación de cálculos o funciones). Esto debe estar detallado en la parte del entregable correspondiente	()
Apoyo en la generación de diagramas, esquemas, mockups o piezas visuales como parte del desarrollo del entregable (especificando parámetros y verificando su fidelidad con la información recopilada). Esto debe estar detallado en la parte del entregable correspondiente	()
No se usó Inteligencia Artificial	()

La herramienta de IA utilizada fue: Google Gemini Advanced, Google LLC.

Todo el contenido generado fue revisado, corregido y validado por la autora/el autor, asegurando precisión, integridad académica y fidelidad con los objetivos del trabajo."